

本节内容

文件的基本概念
&
本章要点总览

前情回顾



文件——就是一组有意义的信息/数据集合

作为系统资源的管理者

提供的功能

处理机管理

存储器管理

文件管理

设备管理

目标

安全、高效




计算机中存放了各种各样的文件，一个文件有哪些属性？
文件内部的数据应该怎样组织起来？
文件之间又应该又应该怎么组织起来？



从下往上看，OS应提供哪些功能，才能方便用户、应用程序使用文件？

从上往下看，文件数据应该怎么存放在外存（磁盘）上？

从最熟悉的 Windows 操作系统出发



文件的属性



一个文件有哪些属性?

文件名: 由创建文件的用户决定文件名, 主要是为了方便用户找到文件, **同一目录下不允许有重名文件**。

标识符: 一个系统内的各文件标识符唯一, 对用户来说毫无可读性, 因此标识符只是操作系统用于区分各个文件的一种内部名称。

类型: 指明文件的类型

位置: 文件存放的路径 (让用户使用)、在外存中的地址 (操作系统使用, 对用户不可见)

大小: 指明文件大小

创建时间、上次修改时间

文件所有者信息

保护信息: 对文件进行保护的访问控制信息

文件内部的数据应该怎样组织起来？

名称	修改日期	类型	大小
test	2018/8/26 14:19	文本文档	1 KB

test - 记事本

文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

从前有座山，
山里有座庙，
庙里有个老和尚在讲故事，
他讲的是：
从前有座山，
山里有座庙，
庙里有个老和尚在讲故事，
他讲的是：
从前有座山，
山里有座庙，
庙里有个老和尚没在讲故事。

无结构文件（如文本文件）——由一些二进制或字符流组成，又称“流式文件”

	A	B	C
1	学号	姓名	性别
2	1120112100	张三	男
3	1120112101	李四	女
4	1120112102	王五	男
5	1120112103	赵六	男
6	1120112104	钱七	女
7	1120112105	狗剩	男
8	1120112106	铁柱	女
9	1120112107	如花	女
10	1120112108	二狗	男
11	1120112109	傻根儿	男
12	1120112110	旺财	女
13			

数据项是文件系统中
最基本的数
据单位

挖掘机
数据挖掘
挖掘机
数据挖掘
数据挖掘
数据挖掘
数据挖掘
数据挖掘
数据挖掘
数据挖掘
数据挖掘

有结构文件（如数据库表）——由一组相似的记录组成，又称“记录式文件”



记录是一组
相关数据项
的集合

文件内部的数据应该怎样组织起来?




有结构文件中，各个记录间应该如何组织的问题——应该顺序存放？还是用索引表来表示记录间的顺序？——这是“文件的逻辑结构”重点要探讨的问题

文件之间应该怎样组织起来？



文件之间应该怎样组织起来？




用户可以自己创建一层一层的目录，各层目录中存放相应的文件。系统中的各个文件就通过一层一层的目录合理有序的组织起来了

目录其实也是一种特殊的有结构文件（由记录组成），如何实现文件目录是之后会重点探讨的问题

所谓的“目录”其实就是我们熟悉的“文件夹”

操作系统应该向上提供哪些功能？




可以“**创建文件**”，
（点击新建后，图形化交互进程在背后调用了“**create 系统调用**”）

可以“**读文件**”，将文件数据读入内存，才能让CPU处理（双击后，“记事本”应用程序通过操作系统提供的“**读文件**”功能，即 **read 系统调用**，将文件数据从外存读入内存，并显示在屏幕上）

可以“**写文件**”，将更改过的文件数据写回外存（我们在“记事本”应用程序中编辑文件内容，点击“保存”后，“记事本”应用程序通过操作系统提供的“**写文件**”功能，即 **write 系统调用**，将文件数据从内存写回外存）

可以“**删除文件**”（点了“删除”之后，图形化交互进程通过操作系统提供的“**删除文件**”功能，即 **delete 系统调用**，将文件数据从外存中删除）



操作系统应该向上提供哪些功能？

向上提供的几个最基本的功能

创建文件 (create系统调用)

删除文件 (delete系统调用)

读文件 (read系统调用)

写文件 (write系统调用)

打开文件 (open系统调用)

关闭文件 (close系统调用)


可用几个基本操作完成更复杂的操作，比如：“复制文件”：先创建一个新的空文件，再把源文件读入内存，再将内存中的数据写到新文件中

操作系统在背后做的处理会在以后进行探讨

读/写文件之前，需要“打开文件”

读/写文件结束之后，需要“关闭文件”

物理地址




从上往下看，文件应如何存放在外存？

操作系统以“块”为单位为文件分配存储空间，因此即使一个文件大小只有10B，但它依然需要占用1KB的磁盘块。外存中的数据读入内存时同样以块为单位


类似于内存分为一个个“内存块”，外存会分为一个个“块/磁盘块/物理块”。每个磁盘块的大小是相等的，每块一般包含2的整数幂个地址（如本例中，一块包含 2^{10} 个地址，即1KB）。同样类似的是，文件的逻辑地址也可以分为（逻辑块号，块内地址），操作系统同样需要将逻辑地址转换为外存的物理地址（物理块号，块内地址）的形式。块内地址的位数取决于磁盘块的大小

与内存一样，外存也是由一个个存储单元组成的，每个存储单元可以存储一定量的数据（如1B）。每个存储单元对应一个物理地址

从上往下看，文件应如何存放在外存？



文件数据放在连续的
几个磁盘块中



文件数据放在离散的几个磁盘块中。
此时，应该如何记录各个磁盘块之间的
先后顺序呢？

“文件的物理结构”
部分会探讨的内容

操作系统又应该
怎么管理空闲磁
盘块？

其他需要由操作系统实现的文件管理功能



文件共享：使多个用户可以共享使用一个文件

文件保护：如何保证不同的用户对文件有不同的操作权限

之后会结合
Windows操作系
统的实际应用进
行探讨

知识点回顾与重要考点

初识文件管理

文件的定义：一组有意义的信息的集合

文件的属性：文件名、标识符、类型、位置、大小、保护信息...

文件内部应该如何被组织起来（文件的逻辑结构）

文件之间应该如何被组织起来（目录结构）

操作系统应向上提供哪些功能（create、delete、open、close、read、write 系统调用）

文件应如何存放在外存中（文件的物理结构）

操作系统如何管理外存中的空闲块（存储空间的管理）

操作系统需要提供的其他文件管理功能

文件共享

文件保护

本节内容

文件的逻辑 结构

知识总览

文件的逻辑结构

无结构文件

有结构文件

顺序文件

索引文件

索引顺序文件

所谓的“逻辑结构”，就是指在用户看来，文件内部的数据应该是如何组织起来的。而“物理结构”指的是在操作系统看来，文件的数据是如何存放在外存中的。

类似于数据结构的“逻辑结构”和“物理结构”。

如“线性表”就是一种逻辑结构，在用户角度看来，线性表就是一组有先后关系的元素序列，如：a, b, c, d, e


“线性表”这种逻辑结构可以用不同的物理结构实现，如：顺序表/链表。顺序表的各个元素在逻辑上相邻，在物理上也相邻；而链表的各个元素在物理上可以是不相邻的。因此，顺序表可以实现“随机访问”，而“链表”无法实现随机访问。

可见，算法的具体实现与逻辑结构、物理结构都有关（文件也一样，文件操作的具体实现与文件的逻辑结构、物理结构都有关）

无结构文件

按文件是否有结构分类，可以分为无结构文件、有结构文件两种。

无结构文件：文件内部的数据就是一系列二进制流或字符流组成。又称“**流式文件**”。如：Windows 操作系统中的 .txt 文件。



文件内部的数据其实就是一系列字符流，没有明显的结构特性。因此也不用探讨无结构文件的“逻辑结构”问题。

有结构文件

按文件是否有结构分类，可以分为无结构文件、有结构文件两种。

无结构文件：文件内部的数据就是一系列二进制流或字符流组成。又称“**流式文件**”。如：Windows 操作系统中的 .txt 文件。

有结构文件：由一组相似的记录组成，又称“**记录式文件**”。每条记录又由若干个数据项组成。如：数据库表文件。一般来说，每条记录有一个数据项可作为**关键字**（作为识别不同记录的ID）

在本例中，“学号”即可作为各个记录的关键字

学号	姓名	性别	专业
1120112100	张三	男	挖掘机
1120112101	李四	女	挖掘机
1120112102	王五	男	数据挖掘
1120112103	赵六	男	挖掘机
1120112104	钱七	女	挖掘机
1120112105	狗剩	男	数据挖掘
1120112106	铁柱	女	数据挖掘
1120112107	如花	女	数据挖掘
1120112108	二狗	男	数据挖掘
1120112109	傻根儿	男	数据挖掘
1120112110	旺财	女	数据挖掘

这是一张数据库表，记录了各个学生的信息

每个学生对应一条记录，每条记录由若干个数据项组成

有结构文件

按文件是否有结构分类，可以分为无结构文件、有结构文件两种。

无结构文件：文件内部的数据就是一系列二进制流或字符流组成。又称“**流式文件**”。如：Windows 操作系统中的 .txt 文件。

有结构文件：由一组相似的记录组成，又称“**记录式文件**”。每条记录又若干个数据项组成。如：数据库表文件。一般来说，每条记录有一个数据项可作为**关键字**。根据各条记录的长度（占用的存储空间）是否相等，又可分为**定长记录**和**可变长记录**两种。

学号	姓名	性别	专业
1120112100	张三	男	挖掘机
1120112101	李四	女	挖掘机
1120112102	王五	男	数据挖掘
1120112103	赵六	男	挖掘机
1120112104	钱七	女	挖掘机
1120112105	狗剩	男	数据挖掘
1120112106	铁柱	女	数据挖掘
1120112107	如花	女	数据挖掘
1120112108	二狗	男	数据挖掘
1120112109	傻根儿	男	数据挖掘
1120112110	旺财	女	数据挖掘

32 B 学号	32 B 姓名	4 B 性别	60 B 专业
------------	------------	-----------	------------

这个有结构文件由**定长记录**组成，每条记录的长度都相同（共 128 B）。各数据项都处在记录中相同的位置，具有相同的顺序和长度（前32B一定是学号，之后32B一定是姓名.....）

有结构文件

按文件是否有结构分类，可以分为无结构文件、有结构文件两种。

无结构文件：文件内部的数据就是一系列二进制流或字符流组成。又称“**流式文件**”。如：Windows 操作系统中的 .txt 文件。

有结构文件：由一组相似的记录组成，又称“**记录式文件**”。每条记录又若干个数据项组成。如：数据库表文件。一般来说，每条记录有一个数据项可作为**关键字**。根据各条记录的长度（占用的存储空间）是否相等，又可分为**定长记录**和**可变长记录**两种。

学号	姓名	性别	特长
1120112100	张三	男	腿特长
1120112101	李四	女	腿毛特长
1120112102	王五	男	熟读唐诗三百首，琴棋书画样样精通，上得了厅堂下得了厨房，精通Java、C++、Python和任何一种脚本语言…(后面还有1万字………)
1120112103	赵六	男	
1120112104	钱七	女	
1120112105	狗剩	男	
1120112106	铁柱	女	
1120112107	如花	女	
1120112108	二狗	男	熟读唐诗三百首，琴棋书画样样精通，上得了厅堂下得了厨房，精通Java、C++、Python和任何一种脚本语言…(后面还有1万字………)
1120112109	傻根儿	男	
1120112110	旺财	女	

32 B 学号	32 B 姓名	4 B 性别	(长度不确定) 特长
------------	------------	-----------	---------------

这个有结构文件由**可变长记录**组成，由于各个学生的特长存在很大区别，因此“特长”这个数据项的长度不确定，这就导致了各条记录的长度也不确定。当然，没有特长的学生甚至可以去掉“特长”数据项。

有结构文件的逻辑结构

按文件是否有结构分类，可以分为无结构文件、有结构文件两种。

无结构文件：文件内部的数据就是一系列二进制流或字符流组成。又称“**流式文件**”。如：Windows 操作系统中的 .txt 文件。

有结构文件：由一组相似的记录组成，又称“**记录式文件**”。每条记录又若干个数据项组成。如：数据库表文件。一般来说，每条记录有一个数据项可作为**关键字**。根据各条记录的长度（占用的存储空间）是否相等，又可分为**定长记录**和**可变长记录**两种。




顺序文件

顺序文件：文件中的记录一个接一个地顺序排列（逻辑上），记录可以是**定长的**或**可变长的**。各个记录在物理上可以**顺序存储**或**链式存储**。

记录0 记录1 记录2 记录3

顺序存储——逻辑上相邻的记录物理上也相邻（类似于顺序表）



链式存储——逻辑上相邻的记录物理上不一定相邻（类似于链表）

顺序文件

串结构

记录之间的顺序与关键字无关

通常按照记录存入的时间决定记录的顺序

顺序结构

记录之间的顺序按关键字顺序排列




假设：已经知道了文件的起始地址（也就是第一个记录存放的位置）

思考1：能否快速找到第 i 个记录对应的地址？（即能否实现随机存取）

思考2：能否快速找到某个关键字对应的记录存放的位置？

顺序文件



需要显式地给出记录长度，假设用1字节表示记录长度

	记录长度	记录内容
0		
L_0+1	L_0	R_0
	L_1	R_1
	...	...
$L_0+L_1+\dots+L_{i-1}+i$	L_i	R_i
	...	...

可变长记录

	记录内容
0	
L	R_0
	R_1
	...
$i*L$	R_i
	...

定长记录

结论：定长记录的顺序文件，若物理上采用顺序存储，则可实现随机存取；若能再保证记录的顺序结构，则可实现快速检索（即根据关键字快速找到对应记录）


注：一般来说，考试题目中所说的“顺序文件”指的是物理上顺序存储的顺序文件。之后的讲解中提到的顺序文件也默认如此。可见，顺序文件的缺点是增加/删除一个记录比较困难（如果是串结构则相对简单）

索引文件



对于可变长记录文件，要找到第 i 个记录，必须先顺序查找前 $i-1$ 个记录，但是很多应用场景中又必须使用可变长记录。如何解决这个问题？

索引号	长度 m	指针 ptr
0	m_0	
1	m_1	
...	...	
i	m_i	
...	...	



逻辑文件

建立一张索引表以加快文件检索速度。每条记录对应一个索引项。

文件中的这些记录在物理上可以离散地存放。

索引表本身是定长记录的顺序文件。因此可以快速找到第 i 个记录对应的索引项。

可将关键字作为索引号内容，若按关键字顺序排列，则还可以支持按照关键字折半查找。

每当要增加/删除一个记录时，需要对索引表进行修改。由于索引文件有很快的检索速度，因此主要用于对信息处理的及时性要求比较高的场合。

另外，可以用不同的数据项建立多个索引表。如：学生信息表中，可用关键字“学号”建立一张索引表。也可用“姓名”建立一张索引表。这样就可以根据“姓名”快速地检索文件了。

(Eg: SQL 就支持根据某个数据项建立索引的功能)

索引顺序文件



思考索引文件的缺点：每个记录对应一个索引表项，因此索引表可能会很大。比如：文件的每个记录平均只占 8B，而每个索引表项占32个字节，那么索引表都要比文件内容本身大4倍，这样对存储空间的利用率就太低了。

键	地址
An Qi	
Bao Rong	
Ding Ding	...
Cao Cao	...
...	...

姓名	其他属性
An Qi	
An Kang	
...	

姓名	其他属性
Bao Rong	
Bao Zi	
...	

逻辑文件

索引顺序文件是索引文件和顺序文件思想的结合。索引顺序文件中，同样会为文件建立一张索引表，但不同的是：并不是每个记录对应一个索引表项，而是一组记录对应一个索引表项。

在本例中，学生记录按照学生姓名的开头字母进行分组。每个分组就是一个顺序文件，分组内的记录不需要按关键字排序

索引顺序文件的索引项也不需要按关键字顺序排列，这样可以极大地方便新表项的插入



用这种策略确实可以让索引表“瘦身”，但是是否会出现不定长记录的顺序文件检索速度慢的问题呢？

索引顺序文件（检索效率分析）

键	地址	姓名	其他属性
An Qi		An Qi	
Bao Rong		An Kang	
Ding Ding	...	...	
Cao Cao	...		
...	...	姓名	其他属性
		Bao Rong	
		Bao Zi	
		...	



用这种策略确实可以让索引表“瘦身”，但是能否解决不定长记录的顺序文件检索速度慢的问题呢？


若一个顺序文件有10000个记录，则根据关键字检索文件，只能从头开始顺序查找（这里指的并不是定长记录、顺序结构的顺序文件），平均须查找 5000 个记录。

若采用索引顺序文件结构，可把 10000 个记录分为 $\sqrt{10000} = 100$ 组，每组 100 个记录。则需要先顺序查找索引表找到分组（共100个分组，因此索引表长度为 100，平均需要查 50 次），找到分组后，再在分组中顺序查找记录（每个分组100 个记录，因此平均需要查 50 次）。可见，采用索引顺序文件结构后，平均查找次数减少为 $50+50 = 100$ 次。

同理，若文件共有 10^6 个记录，则可分为 1000 个分组，每个分组 1000 个记录。根据关键字检索一个记录平均需要查找 $500+500 = 1000$ 次。这个查找次数依然很多，如何解决呢？

多级索引顺序文件

为了进一步提高检索效率，可以为顺序文件**建立多级索引表**。例如，对于一个含 10^6 个记录的文件，可先为该文件建立一张低级索引表，每 100 个记录为一组，故低级索引表中共有 10000 个表项（即 10000 个定长记录），再把这 10000 个定长记录分组，每组 100 个，为其建立顶级索引表，故顶级索引表中共有 100 个表项。



Tips: 要为 N 个记录的文件建立 K 级索引，则最优的分组是每组 $N^{1/(K+1)}$ 个记录。

检索一个记录的平均查找次数是 $((N^{1/(K+1)})/2) * (K+1)$

如：本例中，建立 2 级索引，则最优分组为每组 $100000^{1/3} = 100$ 个记录，平均查找次数是 $(100/2) * 3 = 150$ 次

此时，检索一个记录平均需要查找 $50+50+50 = 150$ 次

知识点回顾与重要考点

文件的逻辑结构

无结构文件



由二进制流或字符流组成，无明显的逻辑结构

由记录组成，分为定长记录、可变长记录

有结构文件



逻辑结构



顺序文件

索引文件

索引顺序文件

知识点回顾与重要考点

串结构：记录顺序与关键字无关

顺序结构：记录按关键字顺序排列

可变长记录的顺序文件在每次查询时只能从头依次查找

默认各记录在物理上顺序存储

顺序文件

可变长记录的顺序文件无法实现随机存取，定长记录可以

定长记录、顺序结构的顺序文件可以快速检索（根据关键字快速找到记录）

最大缺点：不方便增加/删除记录

建立一张索引表，每个记录对应一个表项。各记录不用保持顺序，方便增加/删除记录

索引表本身就是定长记录的顺序文件，一个索引表项就是一条定长记录，因此索引文件可支持随机存取

若索引表按关键字顺序排列，则可支持快速检索

解决了顺序文件不方便增/删记录的问题，同时让不定长记录的文件实现了随机存取。但索引表可能占用很多空间

将记录分组，每组对应一个索引表项

检索记录时先顺序查索引表，找到分组，再顺序查找分组

当记录过多时，可建立多级索引表

要会计算平均查找次数

索引顺序文件

有结构文件

索引文件